

第二部分：概率模型

章宗长

2021年3月10日

内容安排



不确定性的表示

.....●



概率推理

.....●



参数学习

.....●



结构学习

.....●



应用案例：视频监控

.....●

不确定性的表示

- 信念度和概率
- 概率分布
- 联合概率分布
- 条件概率分布
- 贝叶斯网络
- 时序模型

信念度

- 假设绕地遥感卫星突然与地面失去了联系，可能原因：
 - 卫星上的电力系统或通讯系统发生了故障
 - 监控卫星的地面系统发生了故障
- 假如：相比“卫星上有推进器异常”，我们更相信“卫星上有电子异常”
 - 命题E：卫星上有电子异常
 - 命题T：卫星上有推进器异常 那么有： $E \succ T$
- 如果认为E和T有相同的可信程度，那么 $E \sim T$
- 假如：在出现了通讯故障的情况下，相比“卫星上有推进器异常”，我们更相信“卫星上有电子异常”
 - 命题C：出现了通讯故障 那么有： $(E | C) \succ (T | C)$

信念度

- 普适的可比性假设

- $(A | C) \succ (B | C)$, $(A | C) \sim (B | C)$, $(A | C) \prec (B | C)$ 中必有一个成立

- 传递性假设

- 如果 $(A | D) \succcurlyeq (B | D)$, $(B | D) \succcurlyeq (C | D)$, 那么 $(A | D) \succcurlyeq (C | D)$

- 基于这两条假设, 可以用实值函数P来表示**信念度**:

- $P(A | C) > P(B | C)$ 当且仅当 $(A | C) \succ (B | C)$
- $P(A | C) = P(B | C)$ 当且仅当 $(A | C) \sim (B | C)$

信念度和概率

- **（概率论公理）** 假设某个试验的样本空间为 Ω ，对应于其中任一事件 E ，定义一个数 $P(E)$ 。如果 $P(E)$ 满足如下3个公理，则称 $P(E)$ 是事件 E 的概率：
 - 公理1 $0 \leq P(E) \leq 1$
 - 公理2 $P(\Omega) = 1$
 - 公理3 对任一系列互不相容的事件 E_1, E_2, \dots （即如果 $i \neq j$ ，则 $E_i E_j = \emptyset$ ），有

$$P\left(\bigcup_{i=0}^{\infty} E_i\right) = \sum_{i=0}^{\infty} P(E_i)$$

- 假设 P 满足概率论公理，即 $0 \leq P(A | B) \leq 1$
 - 如果 $(A | B)$ 是确定的，那么 $P(A | B) = 1$
 - 如果 $(A | B)$ 是不可能的，那么 $P(A | B) = 0$
 - 如果 $(A | B)$ 介于两者之间，那么 $0 < P(A | B) < 1$

条件概率

$$P(A \mid B) = \frac{P(A, B)}{P(B)}$$

全概率法则

$$P(A \mid C) = \sum_{B \in \mathfrak{B}} P(A \mid B, C) P(B \mid C)$$

\mathfrak{B} : 由互斥且可穷举的命题构成的集合

贝叶斯规则

$$P(A | B) = \frac{P(B | A) P(A)}{P(B)}$$

应用贝叶斯规则：简单实例

- 将未知因素cause造成的结果effect看作证据，确定未知因素cause：

$$P(\text{cause} \mid \text{effect}) = \frac{P(\text{effect} \mid \text{cause}) P(\text{cause})}{P(\text{effect})}$$

- 例子

- 令cause表示命题“病人患有某种传染性肺炎”

- 令effect表示命题“病人核酸检测为阳性”

- $P(\text{effect} \mid \text{cause}) = 1.0$

- $P(\text{cause}) = 1 / 5000$

- $P(\text{effect}) = 0.001$

- $P(\text{cause} \mid \text{effect}) = \frac{P(\text{effect} \mid \text{cause}) P(\text{cause})}{P(\text{effect})} = \frac{1.0 \times \frac{1}{5000}}{0.001} = 0.2$

不确定性的表示

- 信念度和概率
- 概率分布
- 联合概率分布
- 条件概率分布
- 贝叶斯网络
- 时序模型

离散概率分布

示例：概率质量函数

- 离散概率分布


- 在一个离散值集合上的分布
- 表示：概率质量函数

- 二值随机变量 X : $\{0, 1\}$

- $P(x^0) = P(X = 0)$: X 取值为0的概率
- $P(x^1) = P(X = 1)$: X 取值为1的概率

- n 值随机变量 X : $\{1, 2, \dots, n\}$

- $P(x^1), P(x^2), \dots, P(x^n)$
- $P(x^n) = 1 - (P(x^1) + P(x^2) + \dots + P(x^{n-1}))$




连续概率分布

示例：概率密度函数

■ 连续概率分布

- 在一个连续值集合上的分布
- 表示：概率密度函数




- 一个概率密度函数 $p(x)$ 满足： $\int_{-\infty}^{+\infty} p(x)dx = 1$

随着 $dx \rightarrow 0$ ， X 的取值落入区间 $(x, x + dx)$ 的概率

- 累积分布函数 $P(X \in [-\infty, x]) = \int_{-\infty}^x p(x)dx$


— $p(x)$
— $P(X \in [-\infty, x])$



均匀分布

- 均匀分布 $U(a, b)$ 的概率密度函数:

$$U(x | a, b) = \begin{cases} \frac{1}{b - a} & \text{如果 } a \leq x \leq b \\ 0 & \text{否则} \end{cases}$$



- 例子: X 服从均匀分布 $U(0, 10)$, 那么 X 的取值落入区间 $[3, 4]$ 内的概率:


$$\int_3^4 U(x | 0, 10) dx = \frac{1}{10}$$

高斯分布

- 高斯分布（正态分布）：连续随机变量的常见分布形式
- 随机变量服从均值为 μ ，方差为 σ^2 的高斯分布 $\mathcal{N}(w | \mu, \sigma^2)$ ，其密度函数


$$p(w) = \mathcal{N}(w | \mu, \sigma^2) = \frac{1}{\sigma} \phi\left(\frac{w - \mu}{\sigma}\right)$$

$\phi(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$ ：标准的正态密度函数



截断式高斯分布

- 假设用概率密度函数表示飞机在纽约肯尼迪机场的高度分布情况，飞机的高度范围 $[0, 65000]$ 英尺(ft)



- 截断式高斯分布的密度函数

$$\mathcal{N}(w \mid \mu, \sigma^2, a, b) = \frac{\frac{1}{\sigma} \phi\left(\frac{w - \mu}{\sigma}\right)}{\Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)}$$

w : 取值范围 $[a, b]$

$\Phi(x) = \int_{-\infty}^x \phi(x) dx$: 标准的正态累积分布函数


多模态的连续概率分布

■ 高斯混合模型

- 不同高斯分布的加权平均
- 密度函数

$$p(w | \mu_1, \sigma_1^2, \dots, \mu_n, \sigma_n^2, \rho_1, \dots, \rho_n) = \sum_{i=1}^n \rho_i \mathcal{N}(w | \mu_i, \sigma_i^2)$$

其中 $\sum_{i=1}^n \rho_i = 1$



示例：高斯混合模型

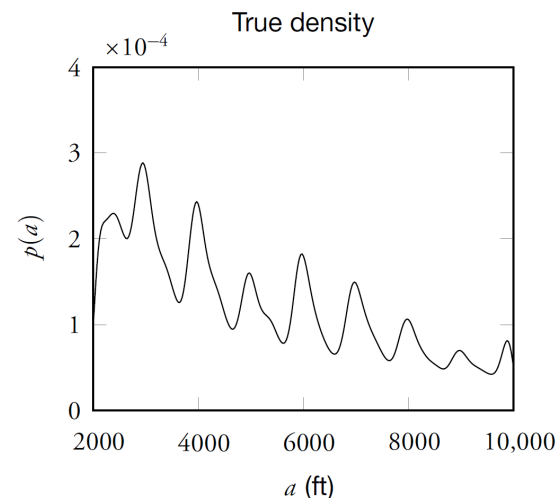
$$\mu_1 = 5, \sigma_1 = 2$$

$$\mu_2 = -5, \sigma_2 = 4$$

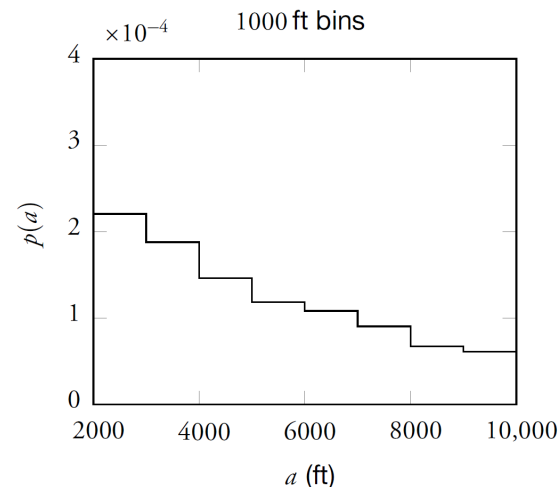
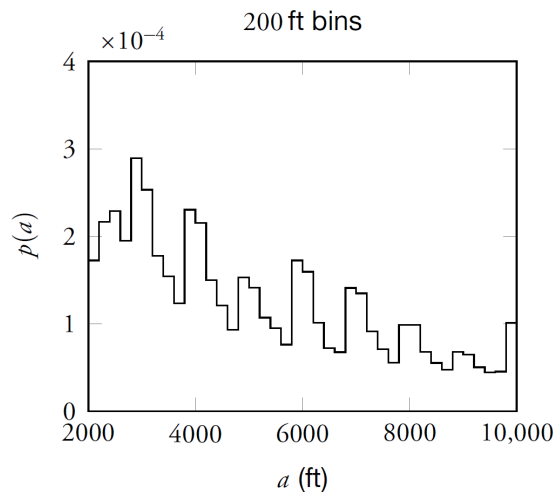

$$\rho_1 = 0.6, \rho_2 = 0.4$$

多模态的连续概率分布（续）

- 右图：飞机在纽约肯尼迪机场的高度范围[2000ft, 10000ft]的概率分布



- 分段均匀密度函数



不确定性的表示

- 信念度和概率
- 概率分布
- 联合概率分布
- 条件概率分布
- 贝叶斯网络
- 时序模型

离散联合分布

示例：联合分布的表格表示

- 联合分布

- 多个随机变量的概率分布

- 建模二值变量 X, Y, Z 的联合分布

- 对这3个变量有8种不同可能的赋值，每种赋值对应一个概率，概率之和为1
- θ_i ：表中第 i 行出现的概率
- $\theta_8 = 1 - (\theta_1 + \theta_2 + \dots + \theta_7)$

X	Y	Z	$P(X, Y, Z)$
0	0	0	0.08
0	0	1	0.31
0	1	0	0.09
0	1	1	0.37
1	0	0	0.01
1	0	1	0.05
1	1	0	0.02
1	1	1	0.07

- 如果有 n 个二值变量，则有 $2^n - 1$ 个独立的参数

- 独立的参数个数的指数增长，带来了表示不确定性和学习概率模型的困难

独立性假设

- 变量 X 和 Y 是独立的, 当且仅当 $P(X, Y) = P(X) P(Y)$, 记为 $X \perp Y$
- $X \perp Y$ 当且仅当 $P(X) = P(X | Y)$
- 如果有 n 个独立的二值变量, 那么能仅用 n 个独立的参数得到联合分布, 而不是 $2^n - 1$ 个

X	Y	Z	$P(X, Y, Z)$
0	0	0	0.08
0	0	1	0.31
0	1	0	0.09
0	1	1	0.37
1	0	0	0.01
1	0	1	0.05
1	1	0	0.02
1	1	1	0.07

如果知道 X, Y, Z
是相互独立的



则独立参数的个
数减少至 $n = 3$

X	$P(X)$	Y	$P(Y)$
0	0.85	0	0.45
1	0.15	1	0.55


Z	$P(Z)$
0	0.20
1	0.80

决策树表示

- 决策树：更紧凑地表示表格中的值

X	Y	Z	$P(X, Y, Z)$
0	0	0	0.01
0	0	1	0.01
0	1	0	0.50
0	1	1	0.38
1	0	0	0.02
1	0	1	0.03
1	1	0	0.02
1	1	1	0.03

存储8个概率值



仅存储5个概率值

多元均匀分布及其混合模型

- 多元均匀分布 $U(\mathbf{a}, \mathbf{b})$ 的概率密度函数:

$2n$ 个独立的参数

$$U(\mathbf{x} | \mathbf{a}, \mathbf{b}) = \prod_{i=1}^n U(x_i | a_i, b_i)$$



- 多元均匀分布的混合模型:

$$p(\mathbf{x} | \mathbf{a}_1, \mathbf{b}_1, \dots, \mathbf{a}_k, \mathbf{b}_k, \rho_1, \dots, \rho_k) = \sum_{j=1}^k \rho_j U(\mathbf{x} | \mathbf{a}_j, \mathbf{b}_j)$$

其中 $\sum_{j=1}^k \rho_j = 1$

$k \times 2n + (k - 1)$ 个
独立的参数

示例: $n = 2, k = 5$ 的多元均匀分布的混合模型及其决策树表示




多元高斯分布

- 多元高斯分布 $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 的概率密度函数:

$$\mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{n/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right)$$

其中 $\mathbf{x} \in \mathbb{R}^n$, $\boldsymbol{\mu}$ 是均值向量, $\boldsymbol{\Sigma}$ 是协方差矩阵

- 示例: 因为 $\boldsymbol{\Sigma}$ 是对称矩阵, 所以独立参数的个数为 $n + (n + 1)n/2$




多元高斯混合模型

- 多元高斯分布的混合模型：

$$p(\mathbf{x} | \boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1, \dots, \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k, \rho_1, \dots, \rho_k) = \sum_{j=1}^k \rho_j \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)$$

其中 $\sum_{j=1}^k \rho_j = 1$

- 示例：



不确定性的表示

- 信念度和概率
- 概率分布
- 联合概率分布
- 条件概率分布
- 贝叶斯网络
- 时序模型

离散条件模型

- 离散变量的条件概率分布
 - 表格表示
 - 给定证据 y 和 z ，所有 x 的概率之和为1

X	Y	Z	$P(X Y, Z)$
0	0	0	0.08
0	0	1	0.15
0	1	0	0.05
0	1	1	0.10
1	0	0	0.92
1	0	1	0.85
1	1	0	0.95
1	1	1	0.90

$$P(x^0 | y^0, z^0) + P(x^1 | y^0, z^0) = 0.08 + 0.92 = 1$$

如果每个随机变量由二值变量变为有 m 个离散值的变量，证据变量的个数由2个变为 n 个，那么表格有多少行？

$$m^{n+1}$$

独立变量的个数是多少呢？

$$(m - 1)m^n$$

条件高斯模型

- 给定一个或多个离散变量，一个连续变量的概率分布

$$p(x | y) = \begin{cases} \mathcal{N}(x | \mu_1, \sigma_1^2) & \text{如果 } y^1 \\ \vdots \\ \mathcal{N}(x | \mu_n, \sigma_n^2) & \text{如果 } y^n \end{cases}$$


2n个独立的参数

线性高斯模型

■ 线性高斯模型： $P(X | Y)$

- 连续随机变量 X 的高斯分布，均值为连续随机变量 Y 取值的线性函数
- 条件概率密度函数：

$$p(x | y) = \mathcal{N}(x | my + b, \sigma^2)$$



$$p(x | y) = \mathcal{N}(x | 2y + 1, 10^2)$$

条件线性高斯模型

- 条件线性高斯模型： $P(X | Y, Z)$
 - 结合了条件高斯模型和线性高斯模型
 - X 和 Y 为连续随机变量， Z 为取值 $1:n$ 的离散随机变量
 - 条件概率密度函数：


$$p(x | y, z) = \begin{cases} \mathcal{N}(x | m_1 y + b_1, \sigma_1^2) & \text{如果 } z^1 \\ \dots & \\ \mathcal{N}(x | m_n y + b_n, \sigma_n^2) & \text{如果 } z^n \end{cases}$$

Sigmoid模型

- Sigmoid模型：给定一个连续变量，一个二值变量的概率分布

- logit模型：
$$P(x^1 | y) = \frac{1}{1 + \exp\left(-2\frac{y - \theta_1}{\theta_2}\right)}$$

- probit模型：
$$P(x^1 | y) = \Phi(y - \theta_1)/\theta_2$$



红色： logit模型
蓝色： probit模型


$$\theta_1 = 0, \theta_2 = 1$$

不确定性的表示


- 信念度和概率
- 概率分布
- 联合概率分布
- 条件概率分布
- 贝叶斯网络
- 时序模型

贝叶斯网络

- 贝叶斯网络是联合分布的一种紧凑表示
- 网络结构：有向无环图
 - 结点：随机变量
 - 有向边（箭头）：联接结点对




卫星监控问题的贝叶斯网络



网络的条件概率


贝叶斯网络中的条件独立关系

- 给定 Z ，变量 X 和 Y 是独立的，当且仅当 $P(X, Y | Z) = P(X | Z) P(Y | Z)$ ，记为 $(X \perp Y | Z)$
 - $(X \perp Y | Z)$ 当且仅当 $P(X | Z) = P(X | Y, Z)$
- 给定父结点（灰色区域中所示的各 U_i ），结点 X 条件独立于它的非后代结点（即各 Z_{ij} ）




链式法则

- $P(X_i | Pa_{X_i})$: 结点 X_i 的条件概率分布
 - Pa_{X_i} 表示 X_i 的父结点
- 链式法则: $P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | Pa_{x_i})$
- 例子
 - $P(b^0, s^0, e^0, d^0, c^0) = P(b^0)P(s^0)P(e^0 | b^0, s^0) P(d^0 | e^0)P(c^0 | e^0)$
 - 贝叶斯网络仅用 $1+1+4+2+2=10$ 个独立的参数来计算这一联合分布




贝叶斯网络的结构


- 贝叶斯网络中三个变量的典型依赖关系：



顺序结构



同父结构



V型结构

- 在**顺序结构**中，给定 x 的值，则 y 和 z **条件独立**
- 在**同父结构**中，给定 x_1 的值，则 x_3 和 x_4 **条件独立**
- 在**V型结构**中，给定 x_4 的值，则 x_1 和 x_2 必**不独立**
- 若 x_4 的取值完全未知，则V型结构下 x_1 和 x_2 却是相互独立的
 - 简单的验证：

$$p(x_1, x_2) = \sum_{x_4} p(x_1, x_2, x_4) = \sum_{x_4} p(x_4 | x_1, x_2) p(x_1) p(x_2) = p(x_1) p(x_2)$$

有向分离 (d-分离, d-separation)

- 给定一个结点集合 \mathcal{G} ，如果 A 和 B 的**所有无向路径**均由 \mathcal{G} 有向分离，记为 $(A \perp B | \mathcal{G})$ ，则称 \mathcal{G} **有向分离** A 和 B
- 如果 A 和 B 的一条路径满足如下任一情况：
 - 包含一个顺序结构： $X \rightarrow Y \rightarrow Z$ ，其中 $Y \in \mathcal{G}$
 - 包含一个同父结构： $X \leftarrow Y \rightarrow Z$ ，其中 $Y \in \mathcal{G}$
 - 包含一个V型结构： $X \rightarrow Y \leftarrow Z$ ，其中 Y 及其后代结点 $\notin \mathcal{G}$则该路径由 \mathcal{G} 有向分离

课前练习



- 给定如下贝叶斯网络，判断下列4个式子的真假。

- $(B \perp D \mid A)$

- $(B \perp D \mid C)$

- $(B \perp D \mid E)$



- $(B \perp C \mid A)$



课前练习


- 给定如下贝叶斯网络，判断下列4个式子的真假。

- $(D \perp I \mid L)$
- $(D \perp J \mid L)$
- $(D \perp J \mid L, I)$
- $(D \perp J \mid L, H, I)$



马尔科夫覆盖



- 马尔科夫覆盖 (Markov Blanket)
 - 有向分离一个结点与其他结点的最少个数的结点构成的集合
 - 这个集合由该结点的父结点、子结点以及子结点的父结点构成



灰色区域为结点 X 的马尔科夫覆盖

课前练习

- 以下是一个隐马尔科夫模型的贝叶斯网络，请找出结点 O_1 的马尔科夫覆盖。



混合贝叶斯网络

- 包含离散的和连续的变量的贝叶斯网络

- 建模 $P(C | W, M)$

- 先忽略二值变量 M ，用线性高斯分布建模

$$p(c | w) = \mathcal{N}(c | \theta_1 w + \theta_2, \theta_3)$$

- 再把二值变量 M 考虑进来，得到

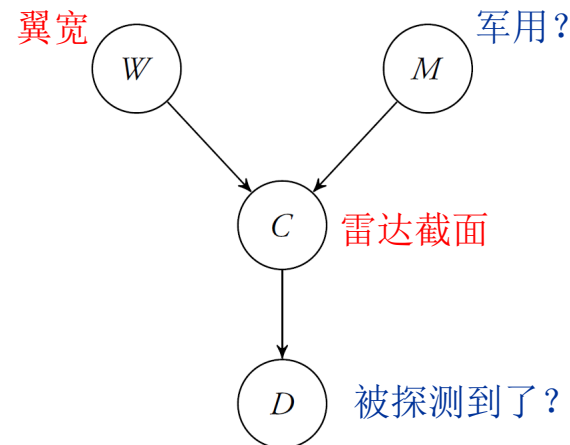
$$p(c | w, m) = \begin{cases} \mathcal{N}(c | \theta_1 w + \theta_2, \theta_3) & \text{如果 } m^0 \\ \mathcal{N}(c | \theta_4 w + \theta_5, \theta_6) & \text{如果 } m^1 \end{cases}$$

- 建模 $P(D | C)$


- 硬性阈值： $P(d^1 | c) = \begin{cases} 0 & \text{如果 } c < \theta \\ 1 & \text{否则} \end{cases}$

- logit模型： $P(d^1 | c) = \frac{1}{1 + \exp\left(-2 \frac{c - \theta_1}{\theta_2}\right)}$

- probit模型： $P(d^1 | c) = \Phi(c - \theta_1)/\theta_2$



连续变量：翼宽、雷达截面
二值变量：军用?、被探测到了?



不确定性的表示

- 信念度和概率
- 概率分布
- 联合概率分布
- 条件概率分布
- 贝叶斯网络
- 时序模型

马尔科夫链

- 时序模型表示一组变量如何随时间演进


- 马尔科夫链

满足马尔科夫性质：系统下一时刻的状态仅由当前状态决定，不依赖于以往的任何状态

- S_t 表示t时刻的状态

- 状态转移模型：条件分布 $P(S_t | S_{t-1})$

- 初始分布： $P(S_0)$



马尔科夫链的贝叶斯网络

- 如果条件分布不随t变化，则称模型是稳态的

马尔科夫链的实例

■ 实例

- 向量 \mathbf{s}_t 表示 t 时刻的状态，由飞机在 t 时刻的高度和垂直速率构成
- 用线性高斯函数表示状态转移分布：

$$p(\mathbf{s}_t | \mathbf{s}_{t-1}) = \mathcal{N}(\mathbf{s}_t | \mathbf{M} \mathbf{s}_{t-1} + \mathbf{b}, \mathbf{\Sigma})$$

$$\text{匀速运动: } \mathbf{M} \mathbf{s}_{t-1} + \mathbf{b} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \mathbf{s}_{t-1}$$


- 初始分布: $p(\mathbf{s}_0) = \mathcal{N}(\mathbf{s}_0 | \boldsymbol{\mu}, \mathbf{\Sigma})$

k维高斯分布：

$$\mathcal{N}(\mathbf{s}_0 | \boldsymbol{\mu}, \mathbf{\Sigma}) = \frac{1}{(2\pi)^{k/2} |\mathbf{\Sigma}|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{s} - \boldsymbol{\mu})^T \mathbf{\Sigma}^{-1} (\mathbf{s} - \boldsymbol{\mu}) \right)$$

隐马尔科夫模型

- 在马尔科夫链上增加观察结点
 - 隐马尔科夫模型：状态变量是离散的



隐马尔科夫模型的贝叶斯网络


线性动态系统

- 在马尔科夫链上增加观察结点
 - **线性动态系统**: 状态变量是连续的且条件分布是线性高斯分布
- 实例
 - 观察是有噪声的高度信息


$$p(\mathbf{o}_t | \mathbf{s}_t) = \mathcal{N}(\mathbf{o}_t | [1 \ 0] \mathbf{s}_t, \mathbf{\Sigma})$$

动态贝叶斯网络

- 可以用动态贝叶斯网络来表示稳态的时序模型
 - 一个贝叶斯网络表示初始分布
 - 一个贝叶斯网络表示转移分布



初始分布



转移分布

小结：不确定性的表示

■ 不确定性的量化

- 信念度、概率
- 条件概率、全概率法则、贝叶斯规则
- 概率分布、联合概率分布、条件概率分布

■ 贝叶斯网络

- 有向无环图，联合分布的一种紧凑表示
- 条件独立关系：有向分离、马尔科夫覆盖
- 混合贝叶斯网络

■ 时序模型

- 表示一组变量如何随时间演进
- 马尔科夫链：状态、状态转移模型、初始分布
- 在马尔科夫链上增加观察结点：隐马尔科夫模型、线性动态系统

课后练习2.1

- 在火星上，有50%的概率既有生命又有水，有25%的概率有生命但没有水，有25%的概率既没有生命又没有水。问：在给定有水的前提下，火星上有生命的概率是多少？



课后练习2.2

- 给定一个状态序列为 $s_{0:t}$ 和观察序列为 $o_{0:t}$ 的隐马尔科夫模型，试证明：

$$P(s_t \mid o_{0:t}) \propto P(o_t \mid s_t, o_{0:t-1})P(s_t \mid o_{0:t-1})$$

请使用上式证明：

$$P(s_t \mid o_{0:t}) \propto P(o_t \mid s_t) \sum_{s_{t-1}} P(s_t \mid s_{t-1}) P(s_{t-1} \mid o_{0:t-1})$$

